

Домашнее задание

Дисциплина	Семинар наставника
Тема	Big Data и ML
Форма проверки	Задание с проверкой преподавателем
Имя преподавателя	Владислав Шевченко
Время выполнения	6 часов
Цель задания	• Спроектировать и реализовать data pipeline. • Применить практики ETL/ELT: извлечение, преобразование, загрузка и партиционирование данных. • Подготовить данные для аналитики и ML-задач (очистка, агрегация, feature engineering). • Применить базовые методы анализа данных и построения ML-моделей. • Визуализировать и интерпретировать результаты.
Инструменты для выполнения ДЗ	• Docker / Docker Compose • PostgreSQL • MinIO (S3-совместимое хранилище) • JupyterHub (Python, pandas, sklearn) • Apache Superset • GitHub / GitLab (репозиторий для сдачи)
Правила приёма работы	Прикрепить в LMS ссылки на репозиторий GitHub. Настройки репозитория должны быть public.
Критерии оценки	• 10 баллов — выполнены все ключевые этапы (инфраструктура, ETL, обработка, ML, визуализация), решение корректно и воспроизводимо, структура проекта и код оформлены аккуратно. Оценка 9–10 возможна при уровне выше ожидаемого: Airflow, Data Quality, incremental-загрузка, оптимизация pipeline. • 8 баллов — реализованы основные этапы (не менее 80% задания), pipeline работает, присутствуют все ключевые компоненты, но есть упрощения или недочёты. • 5-6 баллов — реализована часть задания, есть попытка построения pipeline, но присутствуют ошибки в логике, неполная реализация или проблемы с воспроизводимостью.
Дедлайн	Точная дата указана в LMS

Описание задания:

В рамках задания необходимо реализовать полный аналитический pipeline:

PostgreSQL → ETL → MinIO → обработка → Jupyter → витрины → Superset

Этапы выполнения:

1. Развертывание инфраструктуры

Необходимо:

- Создать docker-compose.yml
- Развернуть:
 - } PostgreSQL
 - } MinIO
 - } Superset
 - } JupyterHub

2. Подключение сервисов

Настроить подключения:

- Jupyter → PostgreSQL
- Jupyter → MinIO (S3 API)
- Superset → PostgreSQL или MinIO (через Presto/Trino опционально)

3. Подготовка данных

Использовать предоставленные SQL-скрипты:

- wells — справочник скважин
- production — ежедневная добыча
- telemetry — телеметрия оборудования

Данные для вставки уже предоставлены (см. SQL файлы)

4. Выгрузка данных в MinIO

Необходимо:

- Считать данные из PostgreSQL
- Преобразовать (pandas / spark)
- Сохранить в MinIO:
 - формат: parquet / csv
 - разбивка по датам (partitioning)

5. Очистка и подготовка данных

Реализовать:

- обработку NULL
- фильтрацию выбросов
- агрегации:
 - по дням
 - по скважинам
- создание фичей:
 - среднее давление
 - средняя температура
 - коэффициент простоя

Практическая часть

Задание 1. Аналитика добычи

Компания получает телеметрию со скважин:

- дебит (тонн/сут)
- давление
- температура
- энергопотребление
- простой оборудования

Необходимо построить аналитические витрины:

1. Общую добычу по дням
2. KPI по скважинам:
 - средний дебит
 - % простоя
3. Найти:
 - лучшие/худшие скважины
 - влияние температуры и давления

В Superset:

- Line chart (добыча по времени)
- Bar chart (топ скважин)
- Heatmap (давление vs дебит)

Задание 2. Прогноз дебита (ML)

На основе данных из таблицы `well_targets` необходимо предсказать **суточный дебит**:

- давление
- температура
- мощность
- время работы насосов

Необходимо:

1. Подготовить dataset:
 - агрегировать telemetry → день
2. Обучить модель:
 - Linear Regression / RandomForest
3. Оценить:
 - MAE / RMSE
4. Сделать прогноз

В Superset:

- Actual vs Predicted
- Ошибка модели по времени

Задание 3. Аномалии и отказ оборудования

На основе данных в таблицах pump_sensors и pump_failures:

- вибрация
- температура
- ток
- обороты

Необходимо:

1. Найти аномалии:
 - z-score / isolation forest
2. Определить:
 - признаки перед отказом
3. Построить модель:
 - вероятность отказа

В Superset:

- Аномалии по времени
- Рост вибрации перед отказом
- Risk score по насосам

Задание 4. Логистика и поставки

На основе данных из таблицы deliveries

Поля:

- маршрут
- объем
- стоимость
- задержка
- погода

Необходимо:

1. Определить факторы задержек:
 - погода
 - расстояние
 - водитель
2. Проанализировать стоимость:
 - cost / km
3. Оптимизировать маршруты

В Superset:

- Delay vs Weather
- Cost vs Distance
- KPI по водителям

Дополнительное задание

*Advanced:

- Реализовать пайплайн через Airflow
- Сделать incremental загрузку
- Добавить Data Quality проверки:
 - NULL %
 - outliers
- Построить витрины:
 - mart_production
 - mart_failures
 - mart_logistics

Чек-лист самопроверки

Необходимо предоставить:

1. Инфраструктура

docker-compose.yml

2. ETL

скрипты выгрузки в MinIO

3. Data Processing

ноутбуки Jupyter

4. ML

модель + метрики

5. BI

дашборды Superset